

다양한 심전도 데이터로부터 부정맥을 예측하는 딥러닝 알고리즘 개발 및 연구

Development of Deep Learning Algorithms for Predicting Arrhythmia from Various ECG Data

요 약

현재 병원에서는 심장질환 환자의 심전도 데이터를 장시간 측정하고, 결과를 심장내과 전문의가 직접 확인 후 부정맥을 진단한다. 따라서 진단에 많은 시간이 소요되며, 굉장히 피로한 작업이다. 이러한 문제점을 해결하고자 본 연구에서는 심장내과 전문의를 대신하여 부정맥을 예측할 수 있는 딥 러닝 모델을 제안한다.

1. 서 론

최근 의학 분야가 발전하면서 수많은 의학 데이터가 생성되고 있지만 이를 분석할 수 있는 인력은 한정되어 있다. 특히 현재 심부전 데이터 분석에 있어서는 심장내과 전문의가 24시간 동안 측정된 심전도 데이터를 모두 직접 확인하는 과정이 필요하다. 이렇듯 한정된 인력으로 장시간 동안 측정된 데이터를 분석하는 것은 상당한 시간을 소모하게 하며 체력적으로도 부담이 되는 작업이다.

이를 해소하기 위해 많은 연구들이 진행되고 있지만, 해결해야 할 문제점들이 아직 존재한다. 대표적으로 정상 ECG 데이터는 충분한 데 반해 심부전 환자의 ECG 데이터는 부족하기 때문에 학습 데이터가 충분치 않다는 점에 있다. 따라서 본 연구에서는 재구성 중심의 접근법을 채택하여 정상 데이터만 학습시켜도 비정상을 탐지할 수 있도록 한다.

비슷한 연구로 AnoGAN[1], Ganomaly[2], BeatGAN[3] 모델이 존재하는데 AnoGAN은 속도 측면에서 낮은 성능을 보이고, Ganomaly는 비정상이 발생한 부분을 정확히 지목할 수 없다. anomaly detection의 핵심 목표는 이 explainability에 있기 때문에 치명적이라 할 수 있다.

BeatGAN의 경우 이 두 가지 문제점을 모두 해결했지만, [그림1]과 같이 신호 그 자체가 아닌 heatmap을 통해서 비정상을 확인할 수 있기에 사람이 인식하기 불편하다는 점이 문제로 남아 있다.

따라서 우리는 심부전을 판단함과 동시에 사람이 직관적으로 쉽게 확인할 수 있도록 입력 신호를 이미지로 변환해 이미지에 직접 이상이 있는 부분을 표시할 수 있는 2D-CNN 기반의 GAN 모델 구성을 목표로 한다.


2. 관련 연구

2.1. Anomaly Detection

ECG와 딥러닝 모델을 이용해 질병을 분석한 대표적인 연구는 Cardiac Arrhythmia 감지이다[4]. ECG 데이터의 ST변화를 모니터링 하는 연구도 진행된 바 있으며[5] Convolutional Neural Network를 통해 Myocardial Infarction(MI), Congestive Heart Failure(CHF) 검출을 자동화[6][7]하는 연구도 있다.

2.2 Localization and Annotation

Localization과 Annotation은 심장병 전문의에게 매우 중요한 연구이다. 질병을 진단하는데 이러한 정보들을 사용하기 때문이다. Auto-Encoder(AE), Recurrent Neural Network(RNN)을 사용하여 12-lead ECG data로부터 심실 급속층의 출구를 자동으로 localization한 연구 [8][9]가 있다. MITBIH Arrhythmia Dataset을 이용해 QRS 복합체에 주석을 다는 연구도 있으며[10], PhysioNet의 QT database를 이용해 ECG 파장에 주석을 다는 다른 방법을 탐구(P,T wave annotation)하는 연구도 있다[11].



[그림 1]

2.3 Denoising

ECG 신호를 수집하는 과정에는 많은 양의 노이즈가 발생하게 된다. 이는 질병 진단의 정확도를 떨어뜨려 부정적인 결과를 초래하며, 특히 원격진료 같은 환경에서는 더욱 부정적인 영향을 준다. Encoder-Decoder CNN을 이용해 노이즈를 줄이는 연구가 있으며[12] Xiong와 Chiang은 Fully-Convolutional-Network-Based Denoising AE를 이용해 Denoising하였다. GAN을 사용해 생성자와 판별자 사이의 Minimax Game을 통해 ECG 노이즈 분포 지식 축적하는 연구도 있다[13].


3. 설계

3.1. 데이터 수집


해당 연구에 사용할 데이터는 MIT-BIH Arrhythmia Database이다. 이 데이터베이스에는 다양한 종류의 심부전증을 나타내는 데이터를 포함하고 있으며 ECG 디러닝 분야의 많은 연구에서 사용되어 왔다. 데이터의 내부는 초당 360hz로 Sampling된 신호로, 2개의 lead로 이루어진 650,000개의 샘플로 구성되어 있다. 우리는 이 전체 샘플 중 가장 특징을 잘 나타내는 2-lead에 대해 320개씩 나누어 GAN의 입력 데이터로 사용하였다. 또한 SVE(S), VEBs(V)를 앓고 있는 환자의 ECG 신호와 정상 신호(N)를 비교해 차이를 계산함으로써 심부전증을 진단할 수 있도록 한다.

3.2. 1D Signal에서 2D Image로의 변환


Signal을 image로 변환하기 위한 방법은 여러 가지가 존재하는데, 본 연구에서는 N, V, S 데이터 각각 15세트에 대하여 Short-Time Fourier Transform(STFT) Gramian Angular Fields(GAFs)를 활용해 이미지 변환을 시도하였다. 정상 데이터의 이미지화 결과는 아래와 같다.



[그림 2] 정상 신호




[그림 3] 정상 신호에 대한 STFT




[그림 4] 정상 신호에 대한 GAFs


정상데이터에 STFT를 적용한 결과 [그림3]과 같이 시간에 따른 주파수 분포를 확인할 수 있었다. 같은 신호를 GAFs로 이미지화를 진행하자 가장 주파수가 높은 150번 데이터 부근에 격자무늬가 출력되었다. 그리고 정상 ECG 15세트에 대해 모두 이와 비슷한 경향이 반복되는 것을 확인하였다. 비정상 신호에 대한 결과는 다음과 같다.



[그림 5] 비정상 신호



[그림 6] 비정상 신호에 대한 STFT 결과

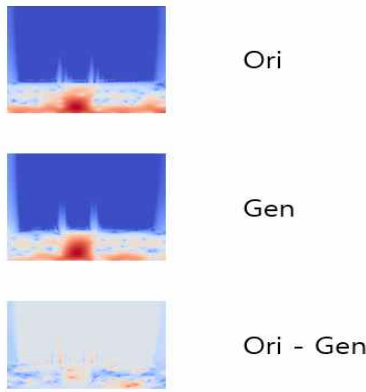


[그림 7] 비정상 신호에 대한 GAFs 결과


[그림6]은 [그림3]에 비해 양 사이드의 주파수 분포가 넓게 퍼져있어 그 차이가 두드러지게 나타난다. 반면 [그림7]은 [그림4]과 비슷한 형상을 띄면서 유의미한 차이를 보이지 못하고 있다. 이러한 현상은 비정상 데이터 V, S 총 30세트에 대해 유사하게 나타났다. 따라서 본 연구에서는 정상 데이터와 비정상 데이터 사이에 확인한 차이를 보일 수 있는 STFT를 활용해 이미지화를 진행하는 것이 적합하다는 판단을 내렸다.

3.3. 일반적 작동방식

BeatGAN은 1-D Conv 구조로 STFT 변환을 거친 이미지를 바로 학습하기에 적절하지 않다. 따라서 2-D Conv 구조로 수정한 뒤, $N_{samples}$ 를 이용해 학습을 진행한다. Test 진행 시, input image x 를 학습된 모델에 넣어 generated image x' 를 획득한다. x 와 x' 를 비교함으로써 비정상 신호를 포착할 수 있다 [그림 8].



[그림 8] 기본 이미지와 GAN을 통해 만들어진 이미지 값의 차이



[그림 9] 네트워크 구조

Reconstruction Error는 Generation Model Optimization과 Anomalousness Scoring으로 나눌 수 있다. 해당 아이디어는 BeatGAN의 논문에서 인용했다.[3]

재구성 모델 손실함수는 다음과 같다:

$$L = \sum_{x=1}^{x+1} \sum_{y=1}^{y+1} \|(x, y) - G(x, y)\|_2 + R(G)$$


x, y 는 이미지 matrix X 의 pixel의 위치를 나타낸다. e.g. $x = 10, y = 10$ 이면 $9 \leq x \leq 11, 9 \leq y \leq 11$ 범위 내의 픽셀 값을 각각 빼준 뒤 L2 Norm 작업을 진행한다. $G()$ 는 생성모델이며, $R(G)$ 는 정규화 파라미터다.

x, y 에 대한 Anomalousness Score는 다음과 같이 계산한다:

$$A(x) = \|(x, y) - G(x, y)\|_2$$

3.4. Generator(G)의 구조

해당 부분의 아이디어는 BeatGAN의 Generator의 구조를 변경하였다[3]. G_e 의 경우, 그림 10과 같이 각 레이어에 2D-CNN 과 Batch-norm, Leaky ReLU가 존재한다. G_D 는 G_e 의 역방향으로 구조화 되어있다.



[그림10] $G_e(x)$ 구조

4. 결론 및 기대효과

기존의 BeatGAN와 달리, STFT과정을 거친 data를 이용함으로써 더 많은 정보를 표현하는 것이 가능하다. 이는 단순히 그래프의 모양(데이터 분포)을 학습하는 것을 넘어 주파수의 변화, 이미지의 특징(색, edge, etc) 등 더 많은 관점에서 학습하는 것이 가능하다. 또한, Abnormal한 Beat를 검출 시 input x 와 생성된 x' 의 차($x-x'$)의 정보를 이용해 파형의 어느 부분으로 인해 검출한 것인지 설명이 가능하다. 이는 전문의의 판단에 큰 도움을 줄 수 있다.

5. 참고문헌

- [1] Thomas Schlegl, Philipp Seeböck, Sebastian M. Waldstein, Ursula Schmidt-Erfurth, Georg Langs 2017. Unsupervised Anomaly Detection with Generative Adversarial Networks to Guide Marker Discovery
- [2] Samet Akcay, Amir Atapour-Abarghouei, Toby P. Breckon 2018. GANomaly: Semi-Supervised Anomaly Detection via Adversarial Training
- [3] Bin Ahou, Shenghua Liu, Bryan Hooi, Xueqi Cheng, Jing Ye., 2019c. BeatGAN: Anomalous Rhythm Detection using Adversarially Generated Time. IJCAI-19.
- [4] Hannun, A.Y., Rajpurkar, P., Haghpanahi, M., Tison, G.H., Bourn, C., Turakhia, M.P., Ng, A.Y., 2019. Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. *Nature medicine* 25, 65.
- [5] Park, Y., Yun, I.D., Kang, S.H., 2019. Preprocessing method for performance enhancement in cnn-based stemi detection from 12-lead ecg. *IEEE Access* 7, 99964-99977.
- [6] Liu, W., Zhang, M., Zhang, Y., Liao, Y., Huang, Q., Chang, S., Wang, H., He, J., 2017. Real-time multilead convolutional neural network for myocardial infarction detection. *IEEE journal of biomedical and health informatics* 22, 1434-1444.
- [7] Wang, L., Zhou, W., Chang, Q., Chen, J., Zhou, X., 2019c. Deep ensemble detection of congestive heart failure using short-term rr intervals. *IEEE Access*.
- [8] Gyawali, P.K., Chen, S., Liu, H., Horacek, B.M., Sapp, J.L., Wang, L., 2017. Automatic coordinate prediction of the exit of ventricular tachycardia from 12-lead electrocardiogram, in: 2017 Computing in Cardiology (CinC), IEEE. pp. 1-4.
- [9] Gyawali, P.K., Horacek, B.M., Sapp, J.L., Wang, L., 2019. Sequential factorized autoencoder for localizing the origin of ventricular activation from 12-lead electrocardiograms. *IEEE Transactions on Biomedical Engineering* .
- [10] Lee, J.S., Lee, S.J., Choi, M., Seo, M., Kim, S.W., 2019b. Qrs detection method based on fully convolutional networks for capacitive electrocardiogram. *Expert Systems with Applications* 134, 66-78.
- [11] Goldberger, A.L., Amaral, L.A., Glass, L., Hausdorff, J.M., Ivanov, P.C., Mark, R.G., Mietus, J.E., Moody, G.B., Peng, C.K., Stanley, H.E., 2000. Physiobank, physiotoolkit, and physionet: components of a new research resource for complex physiologic signals. *Circulation* 101, e215-e220.
- [12] Fotiadou, E., Konopczyński, T., Hesser, J.W., Vullings, R., 2020. End-to-end trained cnn encoder-decoder network for fetal ecg signal denoising. *Physiological Measurement* .
- [13] Wang, J., Li, R., Li, R., Li, K., Zeng, H., Xie, G., Liu, L., 2019b. Adversarial de-noising of electrocardiogram. *Neurocomputing* 349, 212-224.